МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ УНІВЕРСИТЕТ "ЛЬВІВСЬКА ПОЛІТЕХНІКА"

Інститут ІКНІ
Кафедра СШІ

ЗВІТ

до лабораторної роботи № 4

з дисципліни: «Інтелектуальний аналіз та візуалізація даних»
на тему: «Візуальний аналіз даних та часові ряди:
той самий аналіз у двох середовищах»

Лектор:
Виклюк Я.І

Виконав:
ст. гр. ШІ-31
Лопатін В. Д.

Прийняла:
Торська Р.В.
« ___ » _____ 2026 р.

Львів – 2026

Тема роботи: Візуальний аналіз даних та часові ряди: той самий аналіз у двох середовищах.

Мета роботи: Дослідити часовий ряд у Python та Orange, порівняти прогноз із базисами й пояснити розбіжності метрик.

РЕЗУЛЬТАТИ

Варіант: 12. Ринок Zakarpattia, буряк (Beetroots - Retail), грн/кг; 03.2014–12.2017.

Дані: «ціни_україна_2014_2017.csv», конкретний обласний ринок.

Параметри: 46 місячних позицій, 7 фолдів × 3 кроки, ARIMA(1,1,1). Код і повні результати збережено в ноутбуці.

Завдання 1. Підготовка ряду

Ряд відфільтровано за ринком і товаром, упорядковано та приведено до повної місячної сітки. Дублікатів немає, одиниці й валюта узгоджені.

Таблиця 1 — Повнота місячної сітки

Показник	**Результат**
Місячних позицій у періоді	46
Фактичних вимірів	45
Відсутній місяць	Серпень 2017 2017-08-01
Записів у всьому наборі за серпень 2017	0

Висновок. Серпень 2017 відсутній у всьому CSV. Це єдина прогалина нашого ряду; причину відсутності первинних вимірів не задокументовано.

Завдання 2. Заповнення пропуску

Порівняно ffill, лінійну інтерполяцію та bfill. Сусідні ціни: липень — 7,0367, вересень — 6,0700 грн/кг.

Таблиця 2 — Оцінки ціни за серпень 2017

Спосіб	**Значення, грн/кг**
Останнє відоме значення (ffill)	7,03670
Лінійна інтерполяція	6,55335
Наступне відоме значення (bfill)	6,07000

Обрано лінійну оцінку 6,55335 грн/кг: вона локально поєднує дві відомі опори. Це оцінка, не вимір.

Ряди Crimea та m. Sevastopol припиняються у 03.2014 та 04.2014 відповідно; їх подальше заповнення не обґрунтоване.

Висновок. Навчальні відрізки із заповненим серпнем уже містять вересень. Вплив штучної тестової точки окремо перевірено в завданні 7.

Завдання 3. Візуальна розвідка

Лінія показує рівень ціни в календарі; лінійна шкала зберігає абсолютні різниці. Оцінений місяць виділено.



Рисунок 1 — Динаміка ціни буряка на Закарпатті

Річні профілі на спільній шкалі зіставляють ті самі місяці й допомагають виявити сезонне повторення.

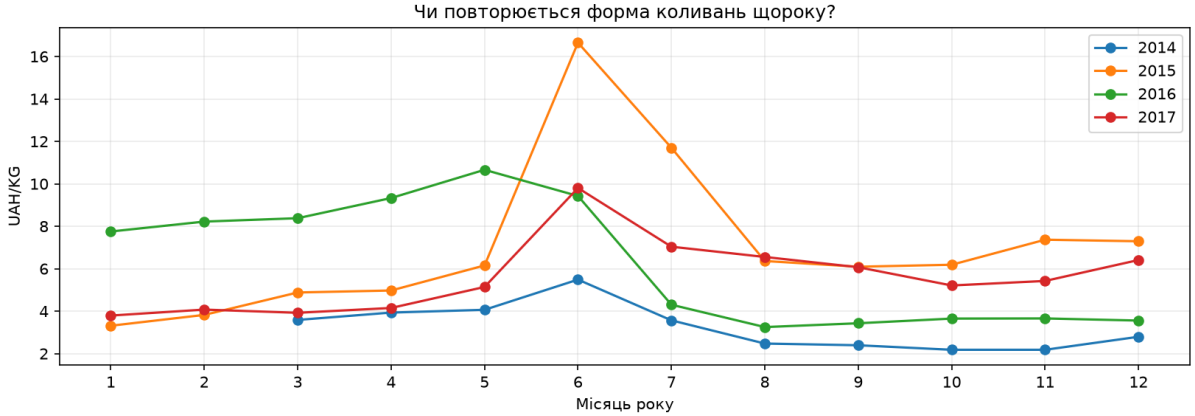


Рисунок 2 — Річні сезонні профілі місячної ціни

Стовпчики перших різниць із нульовою базою показують знак і величину місячних змін.



Рисунок 3 — Перші місячні різниці ціни

Висновок. Найбільша зміна — у 06.2015: +10,4967 грн/кг. Річні профілі відрізняються рівнями та амплітудами.

[Особиста несподівана знахідка: дописати після перегляду графіків.]

Завдання 4. Розкладання на складові

STL: period = 12, robust = True; y = T + S + R. Сили: F_S = max(0; 1 − Var(R)/Var(S+R)); для F_T сезонну складову замінено трендом.

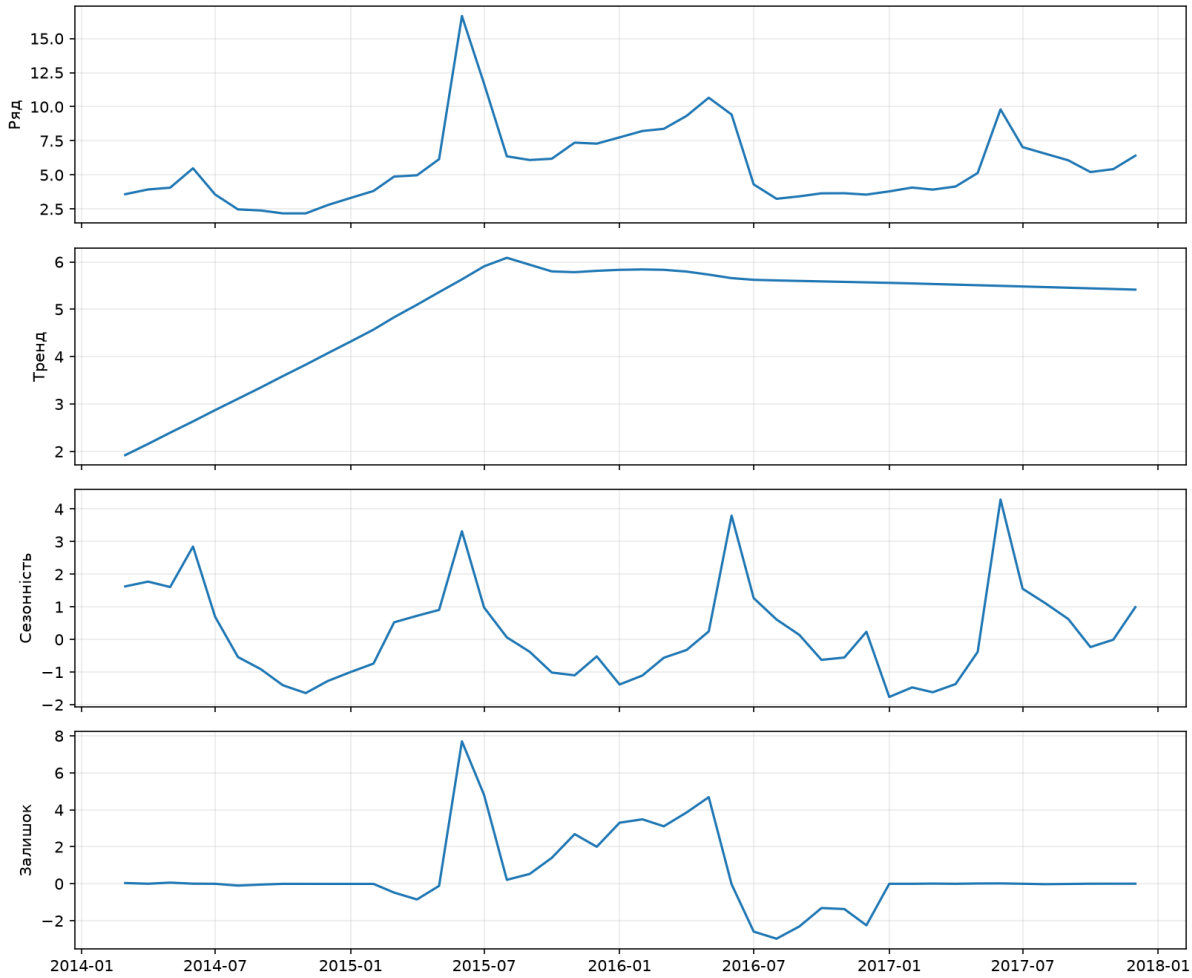


Рисунок 4 — Вихідний ряд, тренд, сезонна складова та залишок STL

Таблиця 3 — Сила складових STL

Величина	**Значення**
Сила сезонності F_S	0.364353
Сила тренду F_T	0.361716
Поріг сезонності за методичкою	0,3

Висновок. F_S = 0,3644 > 0,3: за порогом методички є ознаки сезонності. Менш ніж чотири річні цикли обмежують висновок про її стабільність.

Завдання 5. Стаціонарність

ACF/PACF рівнів і першої різниці: 18 лагів. ADF — константа, AIC; KPSS — константа, auto. Рівень значущості 0,05.

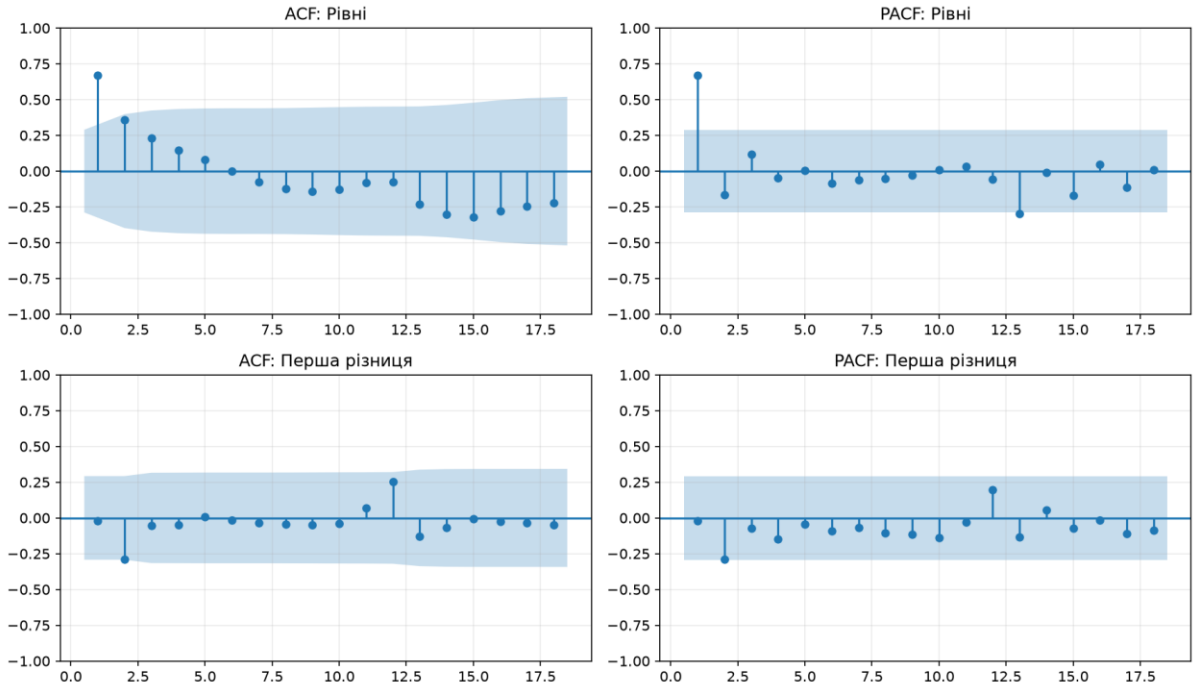


Рисунок 5 — ACF і PACF рівнів та першої різниці

Таблиця 4 — Результати тестів стаціонарності

Ряд	**ADF p**	**KPSS p**	**Лаги ADF / KPSS**
Вихідний ряд	0.040621	> 0,10 (межа таблиці)	0 / 3
Перша різниця	1.0734e-07	> 0,10 (межа таблиці)	1 / 8

H_0 ADF — одиничний корінь; H_0 KPSS — стаціонарність. KPSS p = 0,10 є межею таблиці, не точним значенням.

Висновок. На рівнях ADF p = 0,04062 < 0,05, KPSS не відхиляє стаціонарності; для різниці тести також узгоджуються. d = 1 далі задано умовою роботи.

Завдання 6. Базисні прогнози та ретроспективна перевірка

Перевірено наївний, сезонний наївний, середнє та дрейф на однакових 7×3 фолдах із розширенням навчання.

Таблиця 5 — Ті самі фолди Python та Orange

Фолд Orange	**Навчання**	**N train**	**Тест**
1	03.2014–09.2017	43	10.2017–12.2017

Фолд Orange	**Навчання**	**N train**	**Тест**
2	03.2014–06.2017	40	07.2017–09.2017
3	03.2014–03.2017	37	04.2017–06.2017
4	03.2014–12.2016	34	01.2017–03.2017
5	03.2014–09.2016	31	10.2016–12.2016
6	03.2014–06.2016	28	07.2016–09.2016
7	03.2014–03.2016	25	04.2016–06.2016

Таблиця 6 — Якість чотирьох базисів на 21 прогнозі

Метод	**MAE**	**RMSE**	**MAPE, %**
Наївний	2.008888	2.908642	40.187156
Сезонний наївний	3.701745	4.060900	75.356283
Середнє	2.006303	2.388983	38.449919
Дрейф	2.058247	3.066453	42.125227

Метрики об’єднано за 21 прогнозом: MAE = mean|e|, RMSE = √mean(e²), MAPE = 100 mean|e/y|. MAE/RMSE — грн/кг.

Висновок. Перемогло середнє: RMSE = 2,3890 грн/кг. Воно згладжує короткі стрибки; змінні річні профілі погіршують сезонний наївний прогноз.

Таблиця 7 — Навмисно некоректний випадковий поділ 75/25

Метод	**MAE random**	**RMSE random**	**MAPE random, %**
Наївний	2.461946	2.794982	58.066773
Сезонний наївний	2.752096	3.164634	58.456896
Середнє	2.314804	2.823972	47.773728
Дрейф	2.141944	2.667671	36.792783

Таблиця 8 — Відношення випадкової оцінки до часової

Метод	**MAE random / rolling**	**RMSE random / rolling**	**MAPE random / rolling**
Наївний	1.225527	0.960923	1.444909
Сезонний наївний	0.743459	0.779294	0.775740

Метод	MAE random / rolling	RMSE random / rolling	MAPE random / rolling
Середнє	1.153766	1.182081	1.242492
Дрейф	1.040664	0.869953	0.873414

Random 75/25: random_state = 42. Для відсутніх торішніх train-дат сезонний базис використовує давніший річний відповідник або середнє.

Висновок. Для середнього RMSE random/rolling = 1,182. Випадковий поділ містить майбутнє відносно частини тесту й не оцінює прогноз наступних місяців.

Завдання 7. Модель ARIMA

ARIMA(1,1,1) перенавчено на кожному з тих самих семи train-відрізків; використано стандартні налаштування, як в Orange.

Таблиця 9 — ARIMA та найкращий базис

Метод	MAE	RMSE	MAPE, %
ARIMA(1,1,1)	2.112359	2.840572	41.566458
Середнє	2.006303	2.388983	38.449919



Рисунок 6 — Тримісячні тестові прогнози ARIMA і найкращого базису

Самостійний кандидат — ARIMA(1,0,0): рівні проходять тести; PACF має виразний лаг 1 (0,6690), ACF спадає на лагах 1–3 (0,6690; 0,3559; 0,2309). Його перевагу окремо не перевіряли.

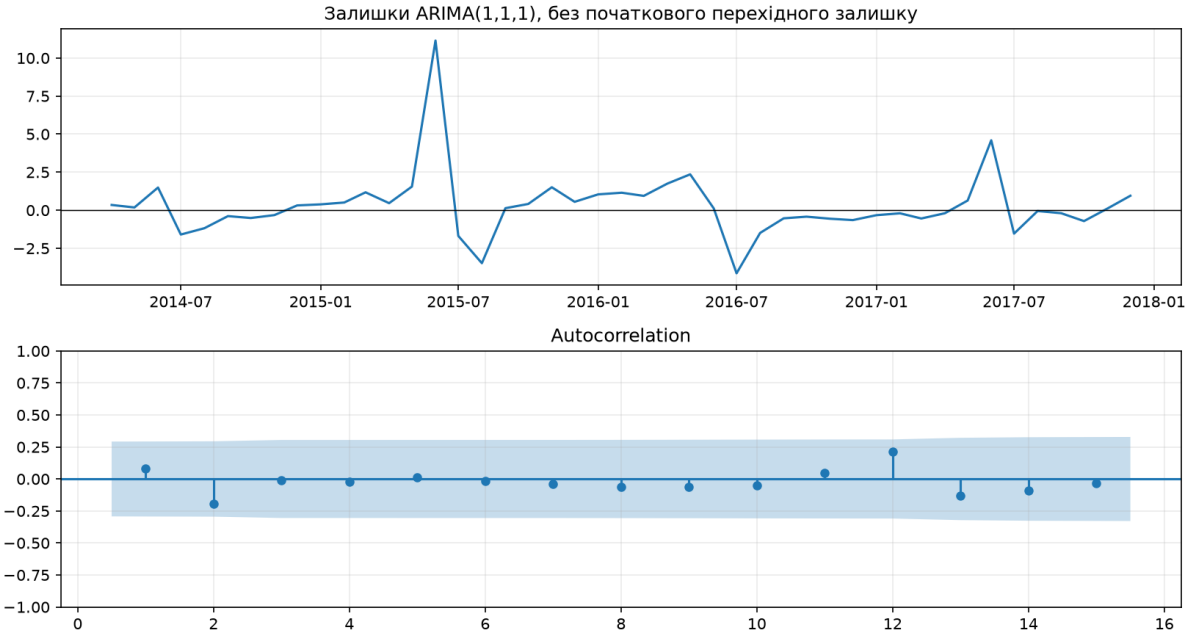


Рисунок 7 — Залишки ARIMA(1,1,1) та їхня ACF

Таблиця 10 — Ljung–Box для залишків, model_df = 2

Лаг	**Статистика**	**p-значення**
6	2.216210	0.696063
12	6.007562	0.814627

Початковий перехідний залишок вилучено. Ljung–Box на лагах 6 і 12 не виявляє автокореляції; це не доводить точності прогнозу.

Без оціненого серпня: 20 тестових вимірів, MAE = 2,040603, RMSE = 2,800547, MAPE = 40,938173%.

Висновок. ARIMA програла середньому за RMSE: 2,8406 проти 2,3890 грн/кг. Переваги над найкращим базисом немає.

Завдання 8. Точка зміни режиму

Скановано 23 межі з мінімум 12 місяцями з кожного боку. Обрано найбільше |t| Welch; дата — перший місяць правого відрізка.



Рисунок 8 — Кандидат зміни рівня та середні до і після межі

Таблиця 11 — Результат сканування

Показник	**Значення**
Обрана дата	03.2015
t-статистика	-5.623350
Середнє до / після, грн/кг	3.316100 / 6.495878
Наївне p Welch	1.20364e-06
p після Бонферроні (23 межі)	2.76837e-05

Висновок. Кандидат — 03.2015. Поправка Бонферроні не усуває автокореляції, тому структурний злам і його зовнішню причину не встановлено. Сезонний пік повторюється, зсув означає тривалу зміну рівня.

Завдання 9. Рецензія на чужий аналіз

Рецензія стосується «ЛР4_помилковий_аналіз.ipynb». Номери — індекси клітинок від нуля; у дужках позиції від одиниці.

Таблиця 12 — Методологічні помилки та їх наслідки

Клітинка	**Помилка**	**Чим небезпечна**
3 (4)	isna без повної сітки	Не виявлено відсутнього місяця.
5 (6)	Купівельна спроможність із ціни одного товару	Немає даних доходів і споживчого кошика.
7 (8)	Порівняння товарів лише за абсолютним MAE	Ігнорується різний масштаб цін.
9 (10)	Кореляцію названо причинним впливом	Спільний тренд не встановлює причини.

Клітинка	**Помилка**	**Чим небезпечна**
11 (12)	STL period=12 на неповній сітці	12 позицій не завжди є роком.
11 (12)	Сезонність лише через наявність S	Не оцінено силу сезонної структури.
13 (14)	Переплутано напрямок H_0 ADF	Хибний висновок про стаціонарність.
13 (14)	Подвійна різниця без перевірки першої	Ризик передиференціювання.
15 (16)	Z-поріг на рівнях із трендом і сезоном	Звичайні рухи оголошено аномаліями.
15 (16)	У тексті 2σ, у коді 1,3σ	Правило не відповідає опису.
17 (18)	Випадковий поділ часового ряду	У train потрапляє майбутнє.
17 (18)	Випадкові train-місяці стиснуто в масив	Спотворено календарні лаги.
17 (18)	Сортування y_test за величиною	Втрачено відповідність факт–прогноз.
17 (18)	Різні дати й горизонти для моделей	Метрики непорівнювані.
17 (18)	«Висока точність» без критерію	Практичну прийнятність не доведено.
19 (20)	Прогноз іншою, неперевіреною ARIMA	Валідація не стосується нової моделі.
19 (20)	Річний прогноз без оцінки невизначеності	Не показано ризик довгого горизонту.
21 (22)	Сильно обрізана вісь стовпчиків	Візуально перебільшено зміни.

Три першочергові виправлення:

1. Клітинки 3/11: повна місячна сітка, виявлення та обґрунтоване заповнення серпневого пропуску.

2. Клітинка 17: перевірка 7×3 на однакових датах для всіх моделей; збереження відповідності дата–факт–прогноз.

3. Клітинка 13: правильна H_0 ADF, додатковий KPSS і перевірка першої різниці перед вибором d.

Висновок. Виявлено 18 методологічних помилок; виконання коду без винятків не гарантує коректності аналізу.

Завдання 10. Експорт ряду для Orange

Експорт: date (YYYY-MM-DD), price; кома, UTF-8, 46 рядків плюс заголовок. Перечитування підтвердило відсутність пропусків і збіг із Python до 10^{-12}.

Таблиця 13 — Контрольні рядки експорту

date	**price**
2014-03-01	3.58670
2017-08-01	6.55335
2017-12-01	6.41000

Висновок. Експорт передає Orange ті самі ціни та календар; повторна інтерполяція їх не змінює.

Завдання 11. Потік опрацювання даних в Orange

Потік: File → Select Columns → Form Timeseries → Interpolate → Line Chart. price — Target, date — Meta/Time; часова змінна date, інтерполяція Linear. Form Timeseries відповідає As Timeseries методички.

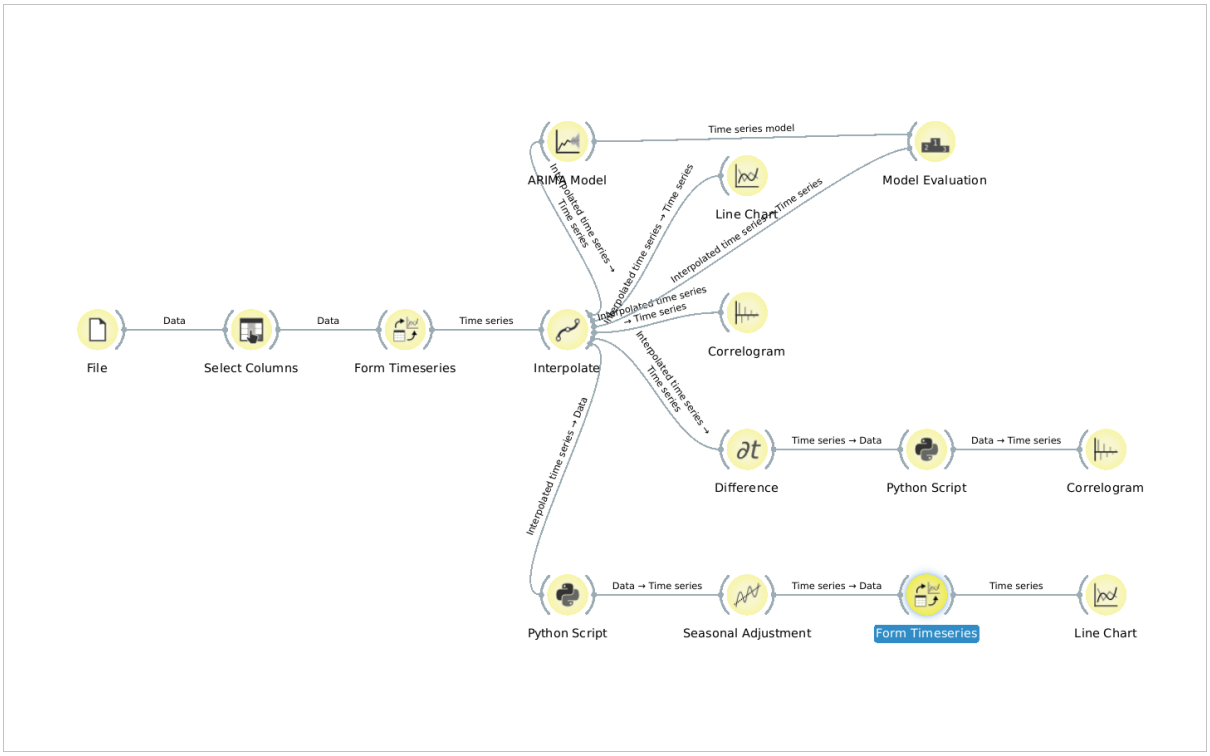


Рисунок 9 — Справжній потік Orange, створений і перевірений автоматично

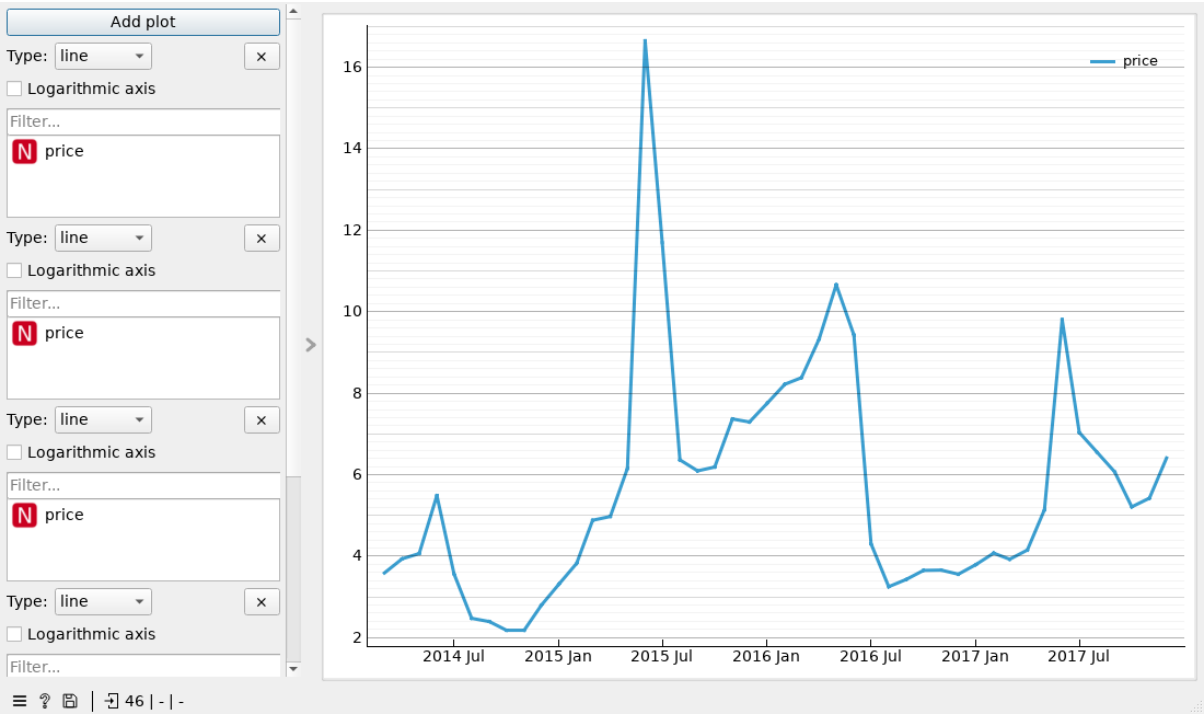


Рисунок 10 — Ціна буряка у штатному Line Chart Orange

Знімки отримано автоматичним запуском справжніх Qt-віджетів (offscreen); вони не засвідчують особисту перевірку студентом.

Висновок. Усі 46 цін і графік збігаються з Python. Потік повторно відкрито, параметри та результати відтворилися.

Завдання 12. Автокореляція та диференціювання в Orange

Додано Correlogram, Difference та Seasonal Adjustment. Після Difference скрипт вилучає невизначену першу різницю: лишається 45 точок.

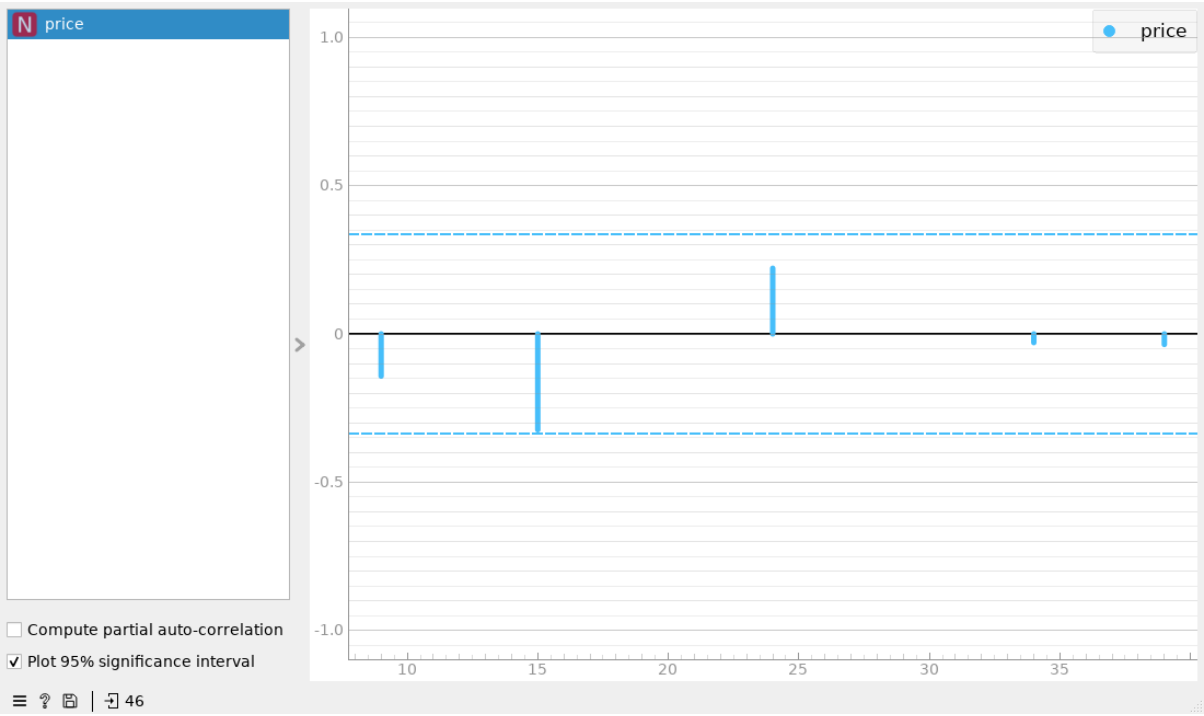


Рисунок 11 — Корелограма рівнів у Orange

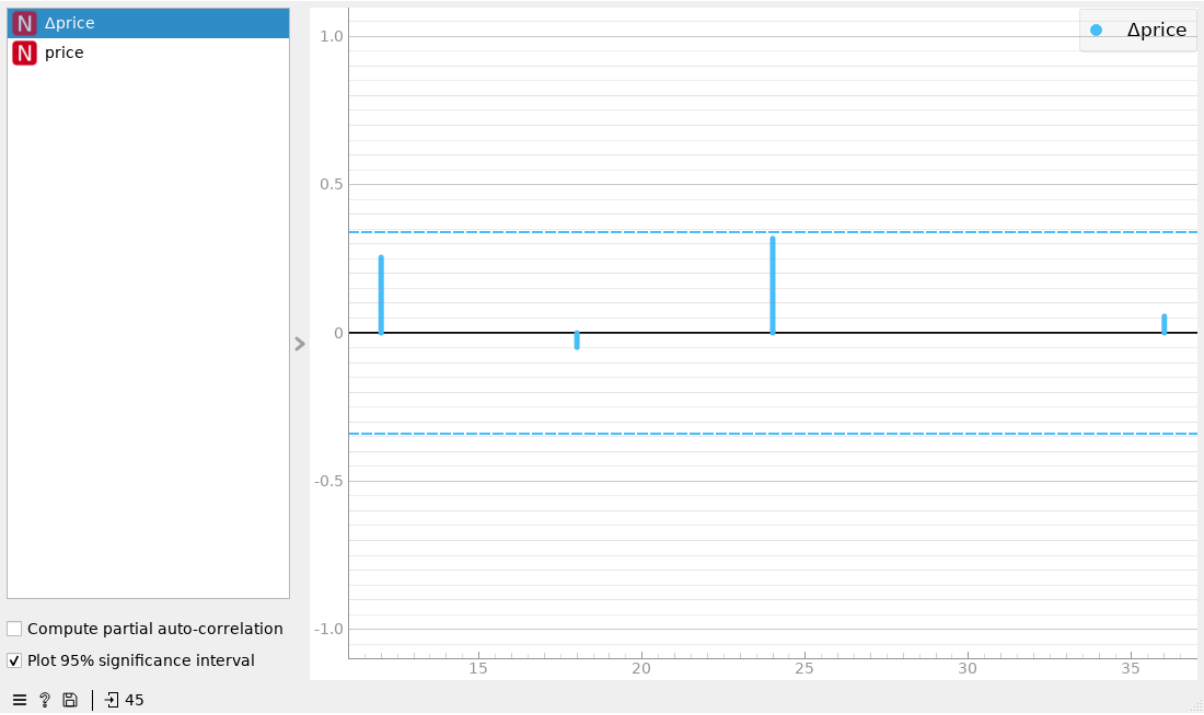


Рисунок 12 — Корелограма 45 перших різниць у Orange

ACF на спільних лагах збігається до 10^{-12}. Orange показує лише локальні піки й інші межі значущості, тому картинки відрізняються.

Python має значущий лаг 1 (0,669), якого Orange не показує як локальний пік. Показані Orange піки незначущі; у різниць Python також немає значущих лагів 1–12.

Помилку «variable date is not in domain» обійдено окремою гілкою: ті самі 46 цін без часових метаданих → Seasonal Adjustment (12, additive) → відновлення місячних дат. Бібліотеку не змінювали.

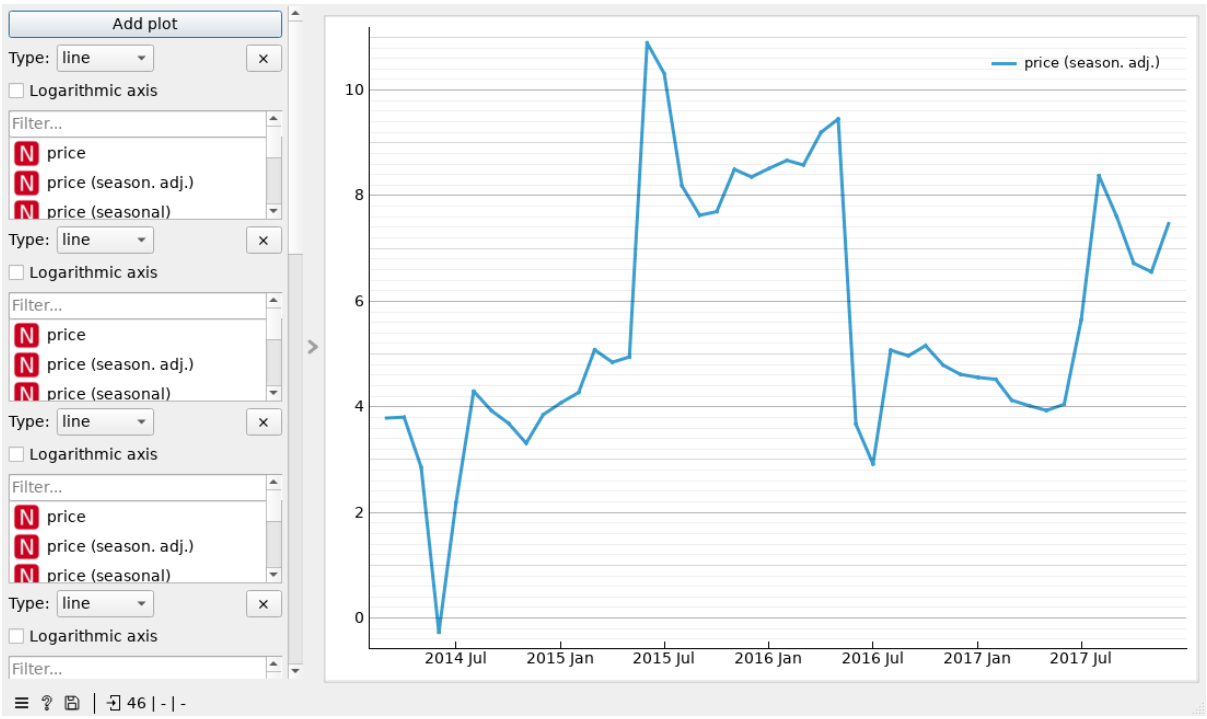


Рисунок 13 — Сезонно скоригований ряд у Orange, additive, період 12

Висновок. Кореляція сезонних складових Orange і STL — 0,7706. Класичне seasonal_decompose та STL різняться алгоритмами; скоригований y−S зберігає зміни рівня.

Завдання 13. Модель і оцінювання в Orange

ARIMA: p=1, d=1, q=1. Model Evaluation отримує ряд і модель; встановлено 7 folds × 3 steps. Порівнюється рядок без (in-sample).

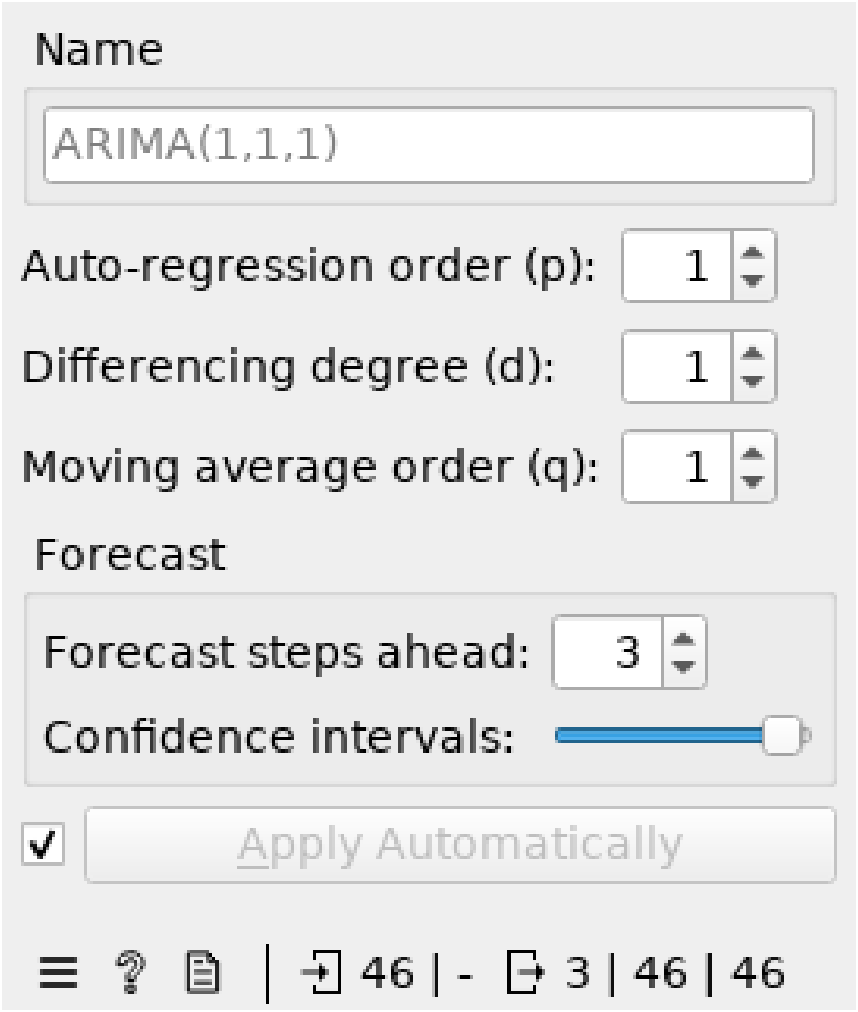


Рисунок 14 — Параметри ARIMA Model у потоці Orange

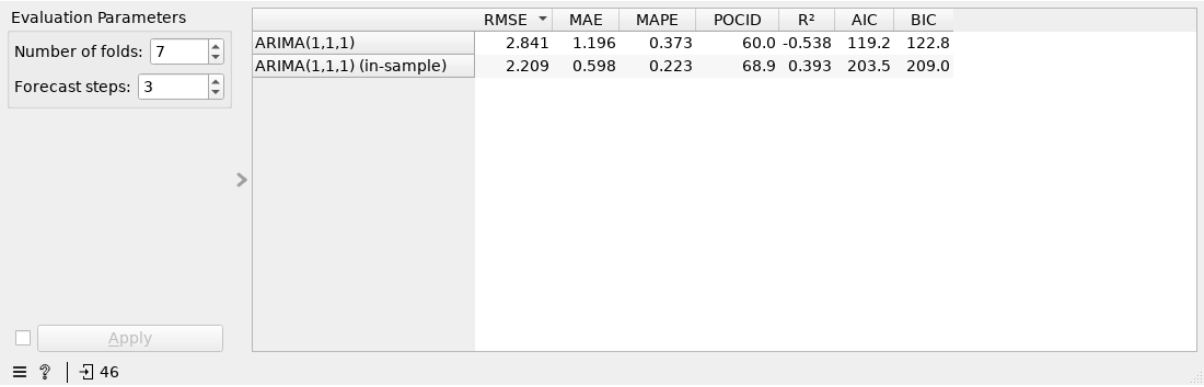


Рисунок 15 — Фактична таблиця Model Evaluation, 7 фолдів × 3 кроки

Типові 20 фолдів неможливі: 20×3+1 = 61 > 46. Фактичне повідомлення:

Unexpected error: Supplied time series is too short for this many folds / step size. Retry with fewer iterations.



Рисунок 16 — Фактична відмова Model Evaluation при 20 фолдах

Висновок. За 7×3 довжини train — 43, 40, 37, 34, 31, 28, 25; перевіряються останні 21 місяць. Потік збережено з 7 фолдами.

Завдання 14. Чому числа метрик не збігаються

Ті самі 21 прогноз склеєно в порядку Orange; e = y−ŷ. Формули відтворено в Python і звірено з віджетом та API.

Таблиця 14 — Відтворення чотирьох метрик Orange

Метрика	**Orange**	**Python**	**Формула**
RMSE	2.841	2.840572	sqrt(mean(e²))
MAE	1.196	1.196063	median(|e|)
MAPE	0.373	0.373240	mean(|e|) / mean(|y|)
POCID	60.000	60.000000	100 mean(Δy × Δŷ > 0)

Чотири значення віджета збігаються до 0,001, прямий API — до 10^{-8}.

Orange MAE — медіана, не середнє: 1,196063 проти 2,112359. Orange MAPE — відношення середніх у частках (0,373240), а звичайний — середнє відносних похибок у % (41,566458). Різниця не лише у множенні на 100.

Висновок. RMSE збігається, бо формула й похибки однакові. Перед порівнянням перевіряють дані, фолди, модель, формулу, агрегування та одиниці метрики.

Завдання 15. Матриця напрямку зміни

Рядки — фактичний напрямок, стовпці — прогнозований. Різниці взято після склеювання фолдів, як у POCID Orange; нульових змін немає.

Таблиця 15 — Матриця напрямків для ARIMA(1,1,1)

Факт / прогноз	**Зросла**	**Впала**
Зросла	6	5
Впала	3	6

POCID = 12/20×100 = 60%. Шість пар — міжфолдові стики, не сусідні місяці. Лише всередині фолдів маємо 7/14 = 50%.

Висновок. Корисність рішення «купувати чи чекати» не доведена: напрямок не враховує величину виграшу, витрати й ризик. MAE/RMSE оцінюють помилку рівня ціни.

ЗАГАЛЬНИЙ ВИСНОВОК

Проаналізовано 46 місяців ціни буряка на Закарпатті. Серпень 2017 заповнено оцінкою 6,55335 грн/кг. F_S = 0,3644 > 0,3 вказує на сезонні ознаки. Тести підтримують стаціонарність рівнів; d = 1 задано умовою. Найкращий базис — середнє (RMSE 2,3890), ARIMA(1,1,1) йому програла (2,8406). Межа 03.2015 є кандидатом зсуву, без доведеної структурної значущості та зовнішньої причини. Аналіз автоматично відтворено в Orange, чотири метрики узгоджено до 0,001. Різницю MAE/MAPE пояснюють формули, RMSE збігається. POCID 60% обмежений міжфолдовими стиками. Короткий ряд не дозволяє встановити довгострокову якість прогнозу та стабільність сезонності.